國立陽明交通大學

NATIONAL YANG MING CHIAO TUNG UNIVERSITY

Artificial Intelligence

Assignment 2

SimCLR on CIFAR-10: Representation Learning Analysis

指導教授：王才沛博士

姓名：劉　順　松

學號：414551016

SimCLR on CIFAR-10：表徵學習分析

SimCLR on CIFAR-10: Representation Learning Analysis

GitHub：https://github.com/414551016/Artifical-Intelligence/tree/main/Hw2

Abstract

本作業旨在探討自監督學習（Self-Supervised Learning, SSL）在無標註資料情境下的影像表示學習能力，並以 SimCLR 對比式學習架構應用於 CIFAR-10 資料集進行實驗分析。本次實作以 Jupyter Notebook 作為主要開發與實驗環境，完成資料載入、模型建構、訓練流程、評估方法、結果視覺化與實驗分析。SimCLR 透過對同一張影像產生兩個不同的資料增強版本，建立正樣本對（positive pairs），並利用 NT-Xent 損失函數，使模型在不使用類別標籤的情況下學習具有判別力的影像特徵表示。

在主要實驗中，本作業使用經過修改的 ResNet-18 作為 backbone encoder，將第一層卷積改為適合 CIFAR-10 影像大小的 3×3 convolution，並移除初始 max-pooling，以避免過早下採樣。SimCLR 訓練時在 encoder 後接上 projection head 進行對比學習；訓練完成後移除 projection head，凍結 encoder，並透過 linear probing 評估 learned representation 的品質。此外，本作業亦建立兩個比較基準：其一為使用標註資料從頭訓練的 supervised learning baseline，其二為隨機初始化且凍結的 backbone 搭配 linear classifier，作為 lower-bound baseline。

實驗結果顯示，SimCLR 模型在 CIFAR-10 linear probing 下達到 84.4% 測試準確率，明顯優於 random frozen backbone baseline 的 34.4%，表示 SimCLR 即使不使用標籤，也能學習到具有分類能力的影像表示。然而，supervised learning baseline 達到 92.97% 測試準確率，顯示在有標註資料的情境下，直接最佳化分類目標仍具有較高效能。此外，訓練過程中的 kNN monitor accuracy 與最終 linear probing accuracy 接近，顯示 kNN monitor 可作為觀察 representation quality 的有效指標。

除了主要實驗外，本作業亦規劃並加入四項延伸實驗以進一步分析 SimCLR 的關鍵因素。Experiment 1 探討 NT-Xent loss 中 temperature 參數對 loss curve 與 kNN monitor accuracy 的影響。Experiment 2 分析 batch size 對 contrastive learning 的影響，特別是 negative samples 數量改變時 representation learning 的差異。Experiment 3 移除 projection head，直接以 encoder output 計算 contrastive loss，以觀察 projection head 對表示品質的重要性。Experiment 4 將 CIFAR-10 上學得的 encoder 轉移至 CIFAR-100 進行 linear probing，以評估 learned representation 的跨資料集泛化能力。

綜合而言，本作業驗證了 SimCLR 對比式自監督學習在無標註影像資料上的有效性。實驗結果顯示，self-supervised learning 能大幅優於隨機特徵表示，並學習出具良好線性可分性的 visual representations；雖然其分類表現仍低於完全監督式學習，但已展現出在缺乏標註資料時作為 representation learning 方法的實用價值與潛力。

關鍵字：

Objective

本次作業的目標是實作並評估一個基於自監督學習（Self-Supervised Learning, SSL）的影像表示學習框架，方法採用 SimCLR，並以 CIFAR-10 資料集作為主要實驗資料。核心目的在於探討：在不使用影像類別標籤的情況下，模型是否能透過對比式學習（contrastive learning）學到具有意義且具判別能力的影像特徵表示。

在 SimCLR 的訓練過程中，模型會對同一張影像產生兩個不同的資料增強版本，並將它們視為正樣本對；同一個 batch 中來自不同影像的樣本則作為負樣本。透過 NT-Xent loss，模型學習使同一張影像的不同增強版本在特徵空間中更接近，而不同影像的表示則彼此分離。藉此，模型可以在無標籤資料上學習出有效的 visual representation。

完成自監督訓練後，本作業會移除 SimCLR 的 projection head，保留 backbone encoder

作為特徵萃取器，並透過 linear probing 評估其學到的表示品質。也就是凍結 encoder，只訓練一個線性分類器來進行 CIFAR-10 分類，以觀察 learned representation 是否具有良好的線性可分性。此外，為了評估 SimCLR 表示學習的效果，本作業也與兩種基準方法進行比較：

- 監督式學習模型（Supervised Learning from Scratch）：
  使用相同的 modified ResNet-18 backbone，但直接利用 CIFAR-10 標籤從頭訓練分類模型，作為有標籤訓練下的比較基準。
- 隨機凍結 backbone 基準模型（Random Frozen Backbone Lower-Bound Baseline）：
  使用隨機初始化且不進行訓練的 backbone，僅訓練最後的線性分類器，作為 representation learning 的下界基準。

透過比較 SimCLR + linear probing、supervised learning 與 random frozen baseline 的測試準確率，本作業希望分析自監督對比式學習是否能有效學習影像特徵，並進一步理解其與監督式學習之間的效能差異。

Methodology

本次作業採用 SimCLR([2002.05709] A Simple Framework for Contrastive Learning of Visual Representations)作為主要的自監督學習方法，並以 CIFAR-10 資料集進行影像表示學習實驗。整體方法包含三個部分：SimCLR 自監督訓練、linear probing 表示評估，以及與 supervised learning 和 random frozen baseline 的比較。

1. SimCLR Framework：

SimCLR 是一種基於 contrastive learning 的自監督表示學習方法。其核心概念是：對同一張影像產生兩個不同的資料增強版本，並讓模型學習使這兩個版本在特徵空間中更接近；同時，來自不同影像的樣本則應在特徵空間中彼此分離。

本作業的 SimCLR 訓練流程如下：

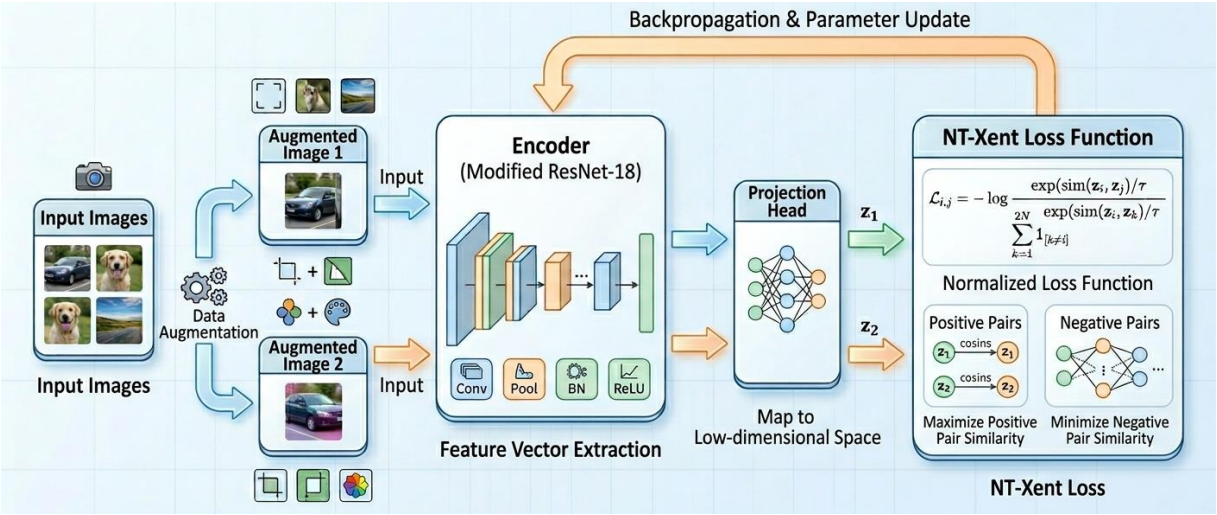

Image → Data Augmentation → Encoder (Modified ResNet-18) → Projection Head → NT-Xent Loss

首先，對每張 CIFAR-10 影像產生兩個獨立的 augmented views。這兩個 views 來自同一張原始影像，因此被視為 positive pair；同一個 batch 中其他影像的 augmented views 則作為 negative samples。接著，兩個 augmented views 會輸入同一個 encoder backbone，產生影像表示向量，再經過 projection head 映射到對比學習使用的 latent space。最後使用 NT-Xent loss 計算 contrastive loss，訓練模型使 positive pair 的 similarity 較高，negative pairs 的 similarity 較低。

本作業使用的主要元件如下：

Component	Description
Backbone Encoder	Modified ResNet-18，調整為適合 CIFAR-10 32×32 影像

Projection Head	Two-layer MLP，結構為 512 → 512 → 128
Loss Function	NT-Xent loss，使用 cosine similarity 與 temperature scaling
Representation for Evaluation	SSL 訓練完成後，移除 projection head，使用 encoder 輸出作為 representation

由於 CIFAR-10 影像大小僅為 32×32，標準 ResNet-18 原本為 ImageNet 設計，若直接使用會在前幾層造成過度下採樣。因此，本作業對 ResNet-18 進行以下修改：

- 將第一層 convolution 從原本的 7×7, stride=2 改為 3×3, stride=1, padding=1。
- 將第一層 convolution 後的 max-pooling layer 改為 identity layer。
- 移除最後的 fully connected layer，保留 global average pooling 後的 512 維 feature 作為 encoder output。

這樣的修改能保留更多 CIFAR-10 小尺寸影像中的空間資訊，使 backbone 更適合本次實驗。

2. Data Augmentation

SimCLR 的關鍵在於資料增強，因為不同的 augmentation views 定義了模型要學習的 invariance。本作業在 SSL 訓練階段對每張影像產生兩個獨立的 augmented views，使用的 transformations 包含：

Augmentation	Purpose
RandomResizedCrop	產生不同局部視角，讓模型學習空間不變性。
RandomHorizontalFlip	增加左右翻轉變化。
ColorJitter	改變 brightness、contrast、saturation、hue。
RandomGrayscale	使模型不過度依賴顏色資訊。
Normalization	使用 CIFAR-10 mean/std 進行標準化。

在 supervised learning 與 linear probing 中，則使用較標準的 CIFAR-10 augmentation，包括 random crop、horizontal flip 與 normalization。測試階段僅進行 normalization，不使用隨機資料增強，以確保評估結果穩定。

3. Training Setup

本次實驗使用 Jupyter Notebook 作為主要開發與執行環境，並在 NVIDIA GeForce GTX 1650 GPU 上進行訓練。為避免 Windows 與 JupyterLab 環境中 PyTorch DataLoader multiprocessing 可能造成卡住的問題，num_workers 設為 0，batch size 設為 64。

主要訓練設定如下：

Component	Setting
Dataset	CIFAR-10
Image size	32×32
Backbone	Modified ResNet-18
Projection head	MLP: 512 → 512 → 128
Batch size	64
Optimizer	Adam
SSL epochs	200
Linear probing epochs	100
Supervised training epochs	200
NT-Xent temperature	0.5
Weight decay	1e-6
Device	NVIDIA GeForce GTX 1650
Environment	Jupyter Notebook 7.5.5

在 SimCLR 自監督訓練過程中，每個 batch 含有 N 張原始影像，經過兩次獨立

augmentation 後形成 2N 張 augmented images。模型會對這 2N 個 samples 計算 pairwise cosine similarity，並透過 NT-Xent loss 進行最佳化。

4. Evaluation Protocol：

本作業使用三種設定進行評估與比較，分別為 SSL + Linear Probing、Supervised Learning Baseline 與 Random Frozen Baseline。

- SSL + Linear Probing：

  首先使用 SimCLR 以自監督方式訓練 encoder，訓練過程中不使用 CIFAR-10 label。SimCLR 訓練完成後，移除 projection head，僅保留 encoder backbone 作為 feature extractor。

  接著進行 linear probing：

  - 凍結 encoder 權重。
  - 在 encoder output 後接上一層 linear classifier。
  - classifier 結構為 512 → 10。
  - 僅訓練 linear classifier，不更新 encoder。
  - 使用 CIFAR-10 labels 訓練 linear classifier，並以 test accuracy 評估 learned representation 的品質。

  此設定的目的在於檢驗 SimCLR 學到的 representation 是否具有良好的線性可分性。如果 frozen encoder 的輸出能讓一個簡單線性分類器取得高準確率，表示該 representation 已包含有用的類別資訊。

- Supervised Learning Baseline：

  第二個設定為 supervised learning baseline。此模型使用與 SimCLR 相同的 modified ResNet-18 backbone，但不使用 projection head，而是在 backbone 後直接接上一個 classification head：

  Modified ResNet-18 Encoder → Linear Classifier (512 → 10)

  整個模型使用 CIFAR-10 labels 從頭訓練，並以標準 cross-entropy loss 作為訓練目標。此 baseline 的目的在於提供一個有標註資料情境下的參考上界，讓我們比較 self-supervised representation learning 與 supervised classification training 之間的效能差距。

- Random Frozen Baseline：

  第三個設定為 random frozen backbone baseline，作為 representation learning 的 lower-bound baseline。此方法使用隨機初始化的 modified ResNet-18 backbone，但不對 backbone 進行任何訓練，直接將其凍結，然後只訓練最後的 linear classifier。

  流程如下：

  Randomly Initialized Encoder → Freeze Encoder → Train Linear Classifier (512 → 10)

  此 baseline 的目的在於檢驗若 encoder 沒有透過 SSL 或 supervised learning 學習，僅使用隨機 CNN features 時，linear classifier 能達到什麼程度的分類能力。若 SimCLR 的 linear probing 結果明顯高於此 baseline，則表示 SimCLR 確實學到了比隨機特徵更有意義的 visual representations。

5. Monitoring During SSL Training：

除了最終的 linear probing 評估外，本作業也使用 kNN monitor 觀察 SimCLR 訓練過程中的 representation quality。具體作法是定期使用目前的 encoder 對 training set 與 test set 萃取 features，並使用 k-nearest neighbors 進行分類評估。

本作業設定：

Item	Setting
kNN k	20。
Monitor frequency	每 5 epochs。
Feature used	Encoder output，而非 projection head output。

kNN monitor 的目的在於即時觀察 representation 是否隨 SSL 訓練逐漸改善。由於

SSL loss 本身不一定能完全反映 downstream task 的表現，因此 kNN accuracy 可作為訓練過程中 representation quality 的輔助指標。

6. Optional Experiments：

除了主要實驗外，本作業也規劃四個延伸實驗，用來進一步分析 SimCLR 中不同設計因素對結果的影響。

- Experiment 1: Temperature Ablation：

  此實驗探討 NT-Xent loss 中 temperature 參數對 contrastive learning 的影響。Temperature 會影響 similarity 分數進入 softmax 前的縮放程度，因此會改變 positive pair 與 negative samples 之間的分離強度。透過比較不同 temperature，例如 0.1、0.5、5.0，可以觀察 SSL loss curve 與 kNN monitor accuracy 是否產生不同變化。

- Experiment 2: Batch Size Ablation：

  此實驗分析 batch size 對 SimCLR 訓練的影響。由於 SimCLR 使用同一個 batch 中的其他 samples 作為 negative samples，因此 batch size 越大，可用的 negative samples 越多，通常有助於 contrastive learning。此實驗可比較不同 batch size 下的 loss curve、kNN accuracy 與 linear probing accuracy。

- Experiment 3: No Projection Head：

  此實驗移除 projection head，直接使用 encoder output 計算 NT-Xent loss。其目的在於驗證 projection head 對 learned representation 的影響。標準 SimCLR 使用 projection head 進行 contrastive loss 計算，但最終 downstream evaluation 使用的是 encoder output。因此，比較有無 projection head 的結果，可以分析 projection head 是否有助於 encoder 學到更好的 representation。

- Experiment 4: CIFAR-100 Transfer Linear Probing：

  此實驗將在 CIFAR-10 上透過 SimCLR 學到的 encoder 轉移到 CIFAR-100 資料集上，並進行 linear probing。此時 encoder 仍然凍結，只訓練新的 linear classifier。其目的在於評估 learned representation 是否具有跨資料集的泛化能力，也就是檢驗其作為 foundation representation 的潛力。

Experimental Results

本節整理本次作業在 CIFAR-10 資料集上的主要實驗結果。實驗主要比較三種模型設定：SimCLR 自監督學習搭配 linear probing、監督式 ResNet-18 baseline，以及 random frozen backbone lower-bound baseline。所有模型皆使用相同的 modified ResNet-18 backbone 架構，以確保比較具有一致性。

1. Final Performance：

本次正式實驗結果如下表所示：

	model	encoder_training	classifier_training	best_test_acc
0	SSL SimCLR + linear probing	self-supervised SimCLR	linear probe only	0.8440
1	Supervised ResNet-18	supervised from scratch	jointly trained	0.9297
2	Random frozen backbone + linear probing	none; random frozen	linear probe only	0.3441

從結果可以觀察到，三種方法的表現排序如下：

Random Frozen Baseline < SSL SimCLR + Linear Probing < Supervised ResNet-18

此結果符合預期。Random frozen baseline 的 encoder 並未經過任何訓練，因此其特徵表示能力最弱；SimCLR 透過自監督對比式學習，在不使用標籤的情況下學習到有效的影像 representation，因此明顯優於 random baseline；而 supervised ResNet-18 直接使用

CIFAR-10 label 最佳化分類目標，因此取得最高測試準確率。

2. SimCLR Self-Supervised Learning Result：

SimCLR 模型在 CIFAR-10 上進行 200 epochs 的自監督訓練。訓練過程中使用 NT-Xent loss，並定期透過 kNN monitor 觀察 representation quality。
最終結果如下：

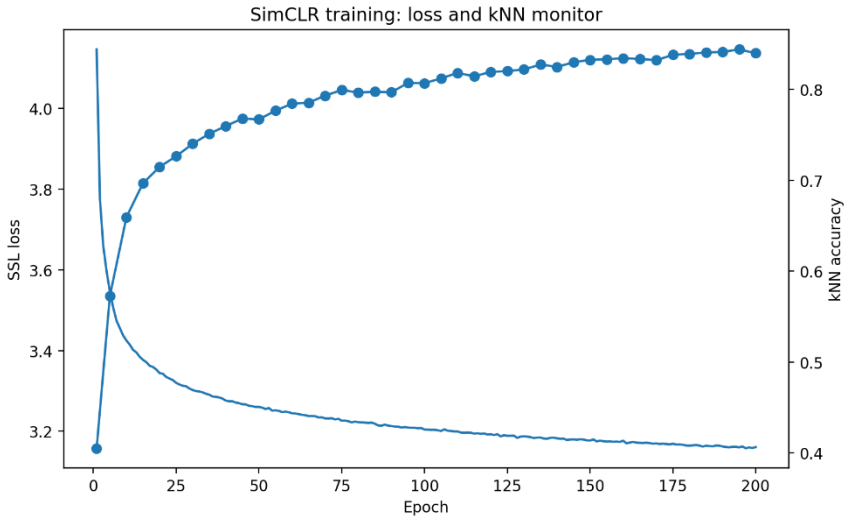

Metric	Result
SSL training epochs	200
Final NT-Xent loss	3.1607
Final kNN monitor accuracy	84.00%
Linear probing best test accuracy	84.40%

從訓練曲線可以觀察到，NT-Xent loss 隨著訓練進行逐漸下降，而 kNN monitor accuracy 則逐步上升，最終達到約 84%。這代表 encoder 在 self-supervised training 過程中逐漸學到更具判別力的 visual representations。
此外，最終 kNN monitor accuracy 約為 84.00%，與 linear probing accuracy 84.40% 非常接近，顯示 kNN monitor 可以有效反映 representation quality，並可作為訓練過程中的輔助評估指標。

3. Linear Probing Result：

在 SimCLR 訓練完成後，本作業移除 projection head，並凍結 modified ResNet-18 encoder。接著在 encoder output 後接上一層 linear classifier，僅訓練該分類器進行 CIFAR-10 分類。
Linear probing 的最佳測試準確率為：84.40%

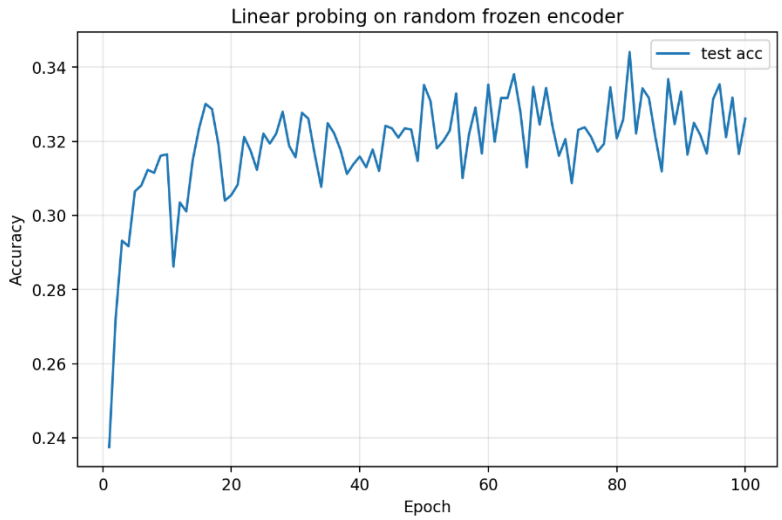

此結果顯示，SimCLR 學到的 encoder representation 具有良好的線性可分性。換言之，即使 encoder 在訓練時未使用任何 CIFAR-10 label，經過 self-supervised contrastive learning 後，其輸出的 feature 已能支援一個簡單線性分類器達到高準確率。

4. Supervised Learning Baseline Result：

Supervised baseline 使用與 SimCLR 相同的 modified ResNet-18 backbone，但不使用 projection head，而是在 backbone 後直接接上 512 → 10 的 classification head。此模型使用 CIFAR-10 label 從頭開始訓練，並以 cross-entropy loss 作為訓練目標。

正式訓練 200 epochs 後，結果如下：

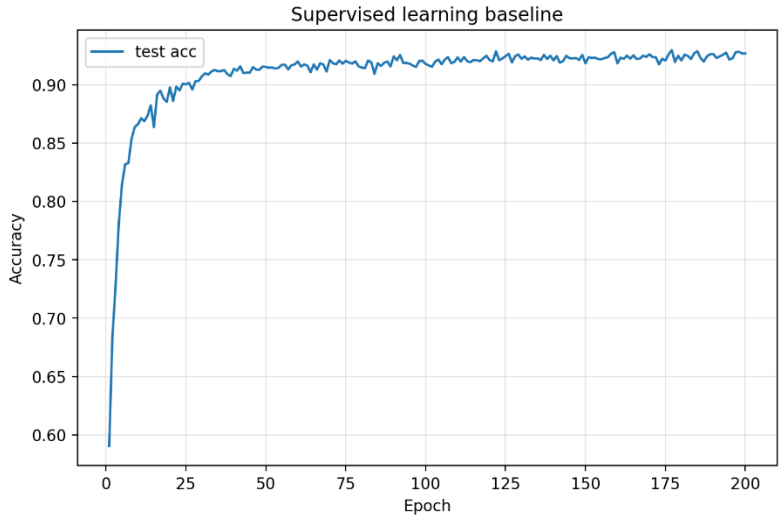

Metric	Result
Supervised training epochs	200
Final training loss	0.0098
Final test accuracy	92.68%
Best test accuracy	92.97%

Supervised baseline 取得本次實驗中最高的測試準確率。這是合理的，因為 supervised learning 直接使用 ground-truth labels 進行訓練，其最佳化目標與最終 CIFAR-10 分類任務完全一致，因此能比 self-supervised learning 取得更高的分類表現。

5. Random Frozen Baseline Result：

Random frozen baseline 使用隨機初始化的 modified ResNet-18 backbone，並將其權重固定不訓練，只訓練最後的 linear classifier。此實驗作為 representation learning 的 lower-bound baseline。

正式 linear probing 訓練 100 epochs 後，結果如下：

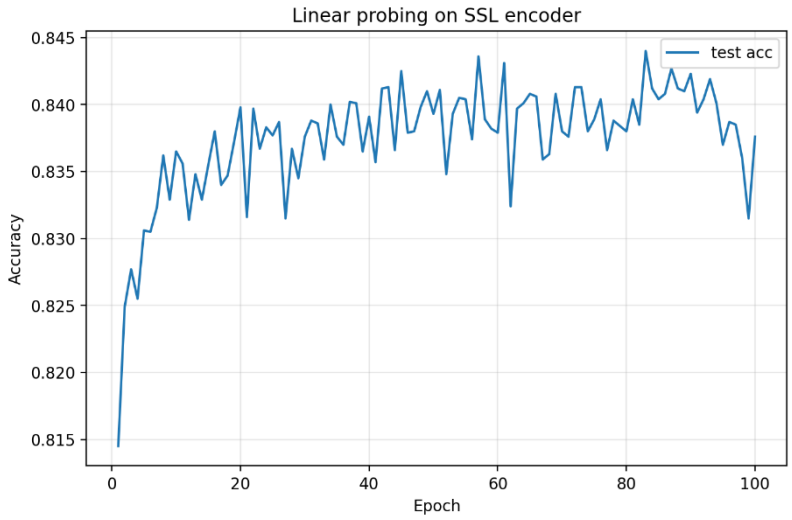

Metric	Result
Linear probing epochs	100
Final training loss	1.9012
Final test accuracy	32.61%
Best test accuracy	34.41%

Random frozen baseline 的最佳測試準確率為 34.41%，明顯低於 SimCLR 的 84.40%。這表示未經訓練的隨機 CNN features 雖然仍可能保留部分低階影像結構資訊，例如邊緣、顏色或局部紋理，但其 representation quality 遠低於透過 SimCLR self-supervised learning 所學得的特徵。

6. Comparative Analysis：

三種方法之間的差異可以進一步整理如下：

Comparison	Accuracy Difference	Interpretation
SimCLR vs Random Frozen	+49.99%	SimCLR 顯著提升 representation quality
Supervised vs SimCLR	+8.57%	使用 label 直接訓練仍具優勢
Supervised vs Random Frozen	+58.56%	有效訓練 backbone 對分類表現至關重要

其中最重要的觀察是：
SimCLR + Linear Probe: 84.40%
Random Frozen Baseline: 34.41%
SimCLR 比 random frozen baseline 高出約 50 percentage points，顯示自監督對比式學習能在不使用標籤的情況下學到非常有用的影像表示。
另一方面，supervised baseline 達到 92.97%，比 SimCLR 高約 8.57 percentage points。這說明 SimCLR 雖然能有效學習 representation，但在完整標籤可用的情況下，supervised learning 仍能取得較佳分類效能。

7. Summary of Experimental Results：

整體而言，本次實驗結果支持以下結論：

- SimCLR 能有效學習 visual representation：
  SimCLR 在 linear probing 下達到 84.40% 測試準確率，遠高於 random frozen baseline。
- 自監督學習顯著優於隨機特徵

Random frozen baseline 僅達到 34.41%，顯示未經訓練的 backbone 無法提供足夠好的分類特徵。

- 監督式學習仍具有最佳分類表現
  Supervised ResNet-18 達到 92.97%，顯示標註資料對分類任務仍有明顯幫助。
- kNN monitor 可反映 representation quality
  SimCLR 最終 kNN accuracy 約 84.00%，與 linear probing accuracy 84.40% 接近，表示 kNN monitor 可作為訓練期間觀察 representation quality 的有效工具。

因此，本次實驗證明 SimCLR 在 CIFAR-10 上能夠透過 self-supervised contrastive learning 學習出具備良好線性可分性的影像表示，雖然仍與 fully supervised learning 存在一定差距，但已展現出在無標註資料情境下的實用性與潛力。

Analysis and Discussion

本節針對本次實驗結果進行分析與討論，重點包含 SimCLR 訓練過程、representation quality、與 supervised learning 和 random frozen baseline 的比較，以及 kNN monitor 是否能有效反映 learned representation 的品質。

1. SimCLR Training Behavior：
   本次 SimCLR 訓練共進行 200 epochs。訓練過程中，SSL loss 從約 4.1 下降至 3.16，而 kNN monitor accuracy 從約 40% 上升至 84%。這表示模型在訓練過程中逐漸學到更好的影像表示。
   此結果顯示：
   - NT-Xent loss 能有效引導模型學習。
   - Encoder 產生的 representation 品質隨訓練提升。
   - kNN accuracy 持續上升，表示沒有發生 representation collapse。
2. Representation Quality: Linear Probing：
   SimCLR 訓練完成後，移除 projection head，凍結 encoder，並訓練 linear classifier。最終 linear probing accuracy 達到 84.4%。
   這代表 SimCLR 學到的特徵具有良好的線性可分性，也就是說，即使 encoder 在訓練時沒有使用 label，其輸出的 feature 仍然包含足夠的類別資訊，使簡單的線性分類器能有效區分 CIFAR-10 類別。
3. Comparison with Supervised Learning：
   Supervised ResNet-18 的最佳測試準確率為 92.97%，高於 SimCLR 的 84.4%，差距約 8.57%。
   這是合理的，因為 supervised learning 直接使用 CIFAR-10 標籤進行訓練，目標就是最佳化分類準確率。相較之下，SimCLR 不使用標籤，而是學習一般性的 visual representation，因此表現略低於 supervised model 是預期結果。
4. Comparison with Random Frozen Baseline：
   Random frozen baseline 的最佳測試準確率為 34.41%，明顯低於 SimCLR 的 84.4%。這表示未經訓練的隨機 CNN features 雖然仍可能保留部分低階影像資訊，但不足以形成高品質 representation。SimCLR 相較 random baseline 提升約 50%，證明 contrastive self-supervised learning 確實能學到有意義且具判別力的影像特徵。
5. kNN Monitor Validation：
   SimCLR 最終 kNN monitor accuracy 約為 84%，與 linear probing accuracy 84.4% 非常接近。
   這表示 kNN monitor 能有效反映 representation quality。由於 SSL loss 不一定能直接代表下游分類能力，因此 kNN monitor 可作為訓練過程中觀察 encoder 是否學到有效特徵的重要指標。
6. Discussion of Factors Affecting Performance：
   本次實驗中，SimCLR 的表現主要受到以下因素影響：
   - Data augmentation：決定 positive pairs 的變化程度，會直接影響模型學到的

invariance。

- Batch size：batch size 越大，negative samples 越多，通常有助於 contrastive learning；本次受限於 GTX 1650，使用 batch size 64。
- Projection head：讓 contrastive loss 作用於 projection space，有助於保留 encoder representation 的品質。
- Training epochs：較長訓練時間能讓 representation quality 持續提升，本次使用 200 epochs 後達到穩定結果。

7. Overall Discussion：

整體而言，本次實驗證明 SimCLR 能在不使用標籤的情況下學到有效的影像表示。SimCLR 的 linear probing accuracy 達到 84.4%，遠高於 random frozen baseline 的 34.41%，顯示其 learned representation 明顯優於隨機特徵。

雖然 supervised learning 仍以 92.97% 取得最佳表現，但 SimCLR 在無標籤訓練下仍能達到相當高的準確率，說明 self-supervised contrastive learning 在缺乏標註資料時具有實用價值與潛力。

Key Insights

- 自監督學習具有成效：
  SimCLR + linear probing 達到 84.4% 測試準確率，明顯高於 random frozen baseline 的 34.41%，表示 SimCLR 能在不使用標籤的情況下學到有效的影像特徵。
- 標註資料仍具有優勢：
  Supervised ResNet-18 達到 92.97%，高於 SimCLR。這表示在有完整標籤的情況下，supervised learning 仍能取得最佳分類表現。
- kNN monitor 可有效觀察 representation quality：
  SimCLR 最終 kNN accuracy 約 84%，與 linear probing accuracy 84.4% 接近，代表 kNN monitor 可作為訓練過程中評估特徵品質的可靠指標。
- Projection head 與 data augmentation 是 SimCLR 的關鍵設計：
  Projection head 有助於 contrastive loss 學習，而 data augmentation 決定模型需要學習的不變性。兩者共同影響 SimCLR representation 的品質。
- SimCLR 學到的 representation 具有良好線性可分性：
  只使用一層 linear classifier 就能達到 84.4%，表示 encoder output 已包含足夠的類別資訊。

Conclusion

本次實驗證明，SimCLR 能夠在不使用標註資料的情況下，透過 self-supervised contrastive learning 學習出具有良好判別能力的影像表示。實驗中，SimCLR 在 CIFAR-10 資料集上經由 linear probing 達到 **84.4%** 的測試準確率，明顯優於 random frozen backbone baseline 的 **34.41%**，顯示模型確實學到了比隨機特徵更有意義的 visual representations。

然而，SimCLR 的表現仍低於 supervised ResNet-18 的 92.97%。這表示在標註資料充足的情況下，supervised learning 仍能透過直接最佳化分類目標取得最佳效能。不過，SimCLR 在完全不使用標籤進行 representation learning 的情況下，仍能取得相當高的分類表現，說明 self-supervised learning 在標註資料不足或取得成本高的情境下具有重要價值。

此外，本次實驗也顯示 kNN monitor accuracy 與 linear probing accuracy 相當接近，代表 kNN monitor 可作為訓練過程中觀察 representation quality 的有效工具。整體而言，本作業驗證了 SimCLR 作為自監督表示學習方法的有效性，並顯示 contrastive learning 能在無標註影像資料上學習出具備良好線性可分性與下游分類能力的特徵表示。

Future Work

1. 探討 temperature 參數影響：
   未來可測試不同 NT-Xent temperature，例如 0.1、0.5、5.0，觀察其對 SSL loss、kNN monitor accuracy 與 linear probing accuracy 的影響，以了解 temperature 是否會影響 positive/negative samples 的分離效果。
2. 分析 batch size 影響：
   SimCLR 會使用 batch 中其他樣本作為 negative samples，因此 batch size 會影響 contrastive learning 的效果。未來可比較不同 batch size，例如 64、128、256、512，分析 negative samples 數量對 representation quality 的影響。
3. 移除 projection head 進行 ablation：
   未來可移除 projection head，直接使用 encoder output 計算 NT-Xent loss，並與原本使用 512 → 512 → 128 projection head 的結果比較，以確認 projection head 是否有助於學習更好的 representation。
4. 轉移學習到 CIFAR-100：
   未來可將在 CIFAR-10 上訓練好的 SimCLR encoder 凍結，並在 CIFAR-100 上訓練新的 linear classifier，以評估 learned representation 是否具有跨資料集的泛化能力。
5. 進一步優化模型與訓練設定：
   若有更充足的 GPU 資源，可嘗試較大的 batch size、更長訓練時間或不同 augmentation policy，進一步提升 SimCLR 的表現。