



國立陽明交通大學

NATIONAL YANG MING CHIAO TUNG UNIVERSITY

Artificial Intelligence

Assignment 3

OpenAI Gym / Gymnasium

Atari MsPacman (DQN)

Atari Enduro (PPO)

指導教授：王才沛博士

姓名：劉 順 松

學號：414551016

OpenAI Gym / Gymnasium

GitHub : <https://github.com/414551016/Artificial-Intelligence/tree/main/Hw3>

Atari MsPacman (DQN)

遊戲位置 : https://ale.farama.org/environments/ms_pacman/

一、遊戲摘要與目標：

MsPacman 不只是單純的反應式任務，而是一個需要結合影像感知、探索策略與長期 reward 預測的強化學習問題。

- 遊戲目標：

- 控制黃色小精靈 (Pac-Man) 在迷宮中移動，吃掉所有的豆子 (pellets) 以獲得分數，同時避免被四隻幽靈 (ghosts) 碰到。

- 如果被幽靈碰到，小精靈會死亡，最多死亡三次或吃完所有豆子，遊戲結束。

- 觀測 (Observation space)：

Atari 遊戲環境預設情況下，環境會回傳遊戲畫面 (RGB 影像)，即人類玩家看到的畫面。AI 代理人如何「看見」或「感知」遊戲狀態，在強化學習中，通常會進行前處理，例如：Box(min, max, shape, dtype): 這是 OpenAI Gym (強化學習環境庫) 中定義觀察空間 (Observation Space) 的標準方式，表示觀察值是一個包含浮點數或整數的矩陣/陣列。

- 灰階化 (grayscale), Box(0, 255, (210, 160), np.uint8)。


- 彩色影像 (RGB Image), Box(0, 255, (210, 160, 3), np.uint8)。

- 隨機存取記憶體 (RAM) 狀態, Box(0, 255, (128,), np.uint8)。

- 動作空間 (Action Space)：

MsPacman 的動作空間大小為 9，包括：

Value	Meaning
0	NOOP
1	UP
2	RIGHT
3	LEFT
4	DOWN
5	UPRIGHT
6	UPLEFT
7	DOWNRIGHT
8	DOWNLEFT



- 遊戲特性：

- 需要策略性地避開幽靈，並盡可能吃掉豆子。

- 吃到能量豆 (power pellet) 後，幽靈會暫時變弱，Pac-Man 可以吃掉幽靈獲得額外分數。

- 在取得能量豆後，判斷是否追擊幽靈。

- 在高風險區域中選擇較安全的移動方向。

- 在長期生存與短期得分之間取得平衡。

二、環境與工具：

- 本實驗使用 Gymnasium 1.2.1、ALE、AutoROM、OpenCV、PyTorch 與 TensorBoard 作為主要開發與訓練工具。MsPacman 的原始 observation 為 Atari 遊戲畫面，也就是 RGB 影像；報告中也列出可能的 observation 型態，包括灰階影像、RGB 影像與 RAM 狀態。

- 為什麼選 MsPacman 作為 DQN 測試環境？

- 經典 Atari 遊戲，畫面複雜度適中，適合驗證 DQN 對像素輸入的學習能力。
- 需要平衡探索與規劃，能測試 ϵ -greedy 策略的效果。
- 有明確的分數回報，適合強化學習的 reward 設計。
- 前處理：AtariPreprocessing（灰階、84x84、frame skip）+ FrameStackObservation（4 幀），這些前處理能降低輸入維度，減少計算成本，並保留對遊戲決策有用的動態資訊。
- DQN 組件：行為/目標網路、Replay Buffer、 ϵ -greedy、MSE 損失、Adam。
- 訓練參數調整：

參數名稱	參數值	說明
training_steps	5,000,000	總訓練步數為五百萬步
eps_decay	500,000	加快探索率下降速度 建議值：300,000 到 500,000
gamma	0.99	保留長期 reward 的影響
batch_size	64	提高 minibatch 訓練穩定性
replay_buffer_size	100,000 以上	提供更多樣化經驗供學習
target_update_freq	每 1000	降低策略震盪
max_steps_per_episode	10,000	控制訓練時間與資源消耗
reward_shaping	如方法實作[勵 塑策略設計]說 明	引導 agent 學習更有效策略 增加吃豆、避開鬼怪等行為的獎勵
clip_reward	可考慮 clip 到 $[-1, 1]$	避免極端獎勵影響學習穩定性
optimizer	Adam/RMSprop	提升梯度更新效率
frame_skip	4 幀	加速訓練並減少重複畫面影響
preprocessing	84x84	降低輸入維度，提升效率 灰階轉換 + resize 到 84x84

- 探索率（Epsilon）分析

參數名稱	參數值	評估
初始 ϵ	1.0	100% 隨機探索。
最小 $\epsilon(\epsilon_{\min})$	0.1	標準值，保留一定探索能力。
ϵ 衰減步數(ϵ_{decay})	1,000,000 步	相對較快，在總 5M 步中只佔 20% 的時間。

三、方法與實作：

- 訓練結果：

```

=====
DQN Atari - Gymnasium + ALE v5
Env ID      : ALE/MsPacman-v5
Use GPU     : False (CUDA available: True)
Training steps : 5,000,000
Batch size  : 64
LR          : 0.0001
Gamma       : 0.99
Replay capacity : 500,000
Update freq : 4
Target update : 10000
Warmup steps : 50,000
Epsilon min  : 0.1
Eval eps     : 0.01
Eval interval : 500
Eval episodes : 5
Log dir      : log/DQN/MsPacman/

=====
A.L.E: Arcade Learning Environment (version 0.11.2+ecc1138)
[Powered by Stella]

=====
Evaluating...
episode 1 reward: 250.00
episode 2 reward: 170.00
episode 3 reward: 190.00
episode 4 reward: 120.00
episode 5 reward: 90.00
average score: 164.00
=====

```

- 神經網絡計設：
本實驗採用 Deep Q-Network, DQN 作為主要演算法。DQN 使用神經網路近似 action-value function $Q(s,a)$ ，用來估計在狀態 s 下執行動作 a 後，未來可能獲得的

累積 reward。

$$Q_{target} = r + \gamma \max_{a'} Q_{target}(s', a')$$

其中 r 是目前步驟獲得的 reward， γ 是 discount factor， s' 是下一個狀態， a' 是下一個狀態中可能的動作。


為了提升訓練穩定性，本實驗使用以下 DQN 組件：

Component	說明
Online network	根據目前狀態選擇動作並更新參數
Target network	提供較穩定的 Q-learning target
Replay buffer	儲存過去經驗，降低樣本之間的相關性
ϵ -greedy	在探索與利用之間取得平衡
MSE loss	計算 predicted Q-value 與 target Q-value 的差距
Adam optimizer	更新神經網路參數

- 加入 Learning Rate Scheduler (學習率排程器) 在訓練神經網路時，學習率是一個至關重要的超參數，它決定了模型參數 (權重) 每次更新的步長 (step size)。將預先定義了一套規則或策略，隨著學習率隨著訓練的進度 (例如訓練的 epoch 數或 batch 數) 自動調整。
- 獎勵塑造 (reward shaping) 策略設計：
針對 MsPacman 遊戲設計的強化獎勵與懲罰策略，旨在獎勵積極探索、策略性使用能量豆以及高效地吃掉幽靈：
 1. 吃普通豆子 (Pellet)：原始獎勵 10 分。強化：額外 +0.1。
目的：鼓勵持續移動和探索。
 2. 吃能量豆 (Power Pellet)：原始獎勵 50 分。強化：額外 +5.0。
目的：凸顯能量豆的戰略價值，讓 Pac-Man 優先尋找。
 3. 吃幽靈 (Ghost)：原始獎勵 200, 400, 800, 1600。強化：額外 +5.0 ~ +20.0 (依連續性)。
目的：強化高分行為與解除危機，這必須較有遠視折扣因子。由於原始分數已很高，這裡的強化值不宜過大，主要做為即時信號。
 4. 避開非可食幽靈 (Avoid Non-Edible Ghost)：
懲罰：當 Pac-Man 距離非可食幽靈過近時，施加負向懲罰，如 -0.01 ~ -0.1。距離越近，懲罰越大。
目的：學習預防性地躲避危險，避免在學習後期才因死亡 (巨額懲罰) 而反覆試錯。
 5. 停止不動懲罰 (NOOP)：
目的：為了避免 Agent 停在原地不動被幽靈包圍而死，在環境的 step 函式中追蹤 Agent 的動作，並在它選擇不動的動作時施加一個小的負向獎勵 (懲罰)，如 -0.05。
 6. 生命值損失 (最關鍵的懲罰塑造)：
目的：避免死亡是最高優先級，生命值損失，施加巨大的即時懲罰如 -50.0。


四、實驗結果與分析：

- 實驗結果：




- 本實驗使用 DQN-based agent 在 Atari MsPacman 環境中訓練 5,000,000 steps。圖 X 顯示 evaluation average reward 隨訓練步數的變化，圖 Y 則同時呈現 training reward 與 evaluation average reward。
- 從 evaluation average reward 曲線可以觀察到，訓練初期 agent 的平均 reward 較低，大約落在 100 到 200 分左右。此時 agent 主要仍依賴隨機探索，尚未形成穩定策略。隨著訓練步數增加，average reward 在約 1.5M steps 後開始明顯提升，並在約 3.4M steps 附近達到最高點，超過 1,000 分。這表示 agent 已逐漸學到部分有效行為，例如持續吃豆子、避免快速死亡，以及在部分狀態下取得較高分數。
- 然而 evaluation average reward 在達到高點後仍出現明顯下降，之後又逐漸回升。這表示 agent 的策略尚未完全穩定收斂。雖然 DQN 能夠學到部分有效策略，但在 MsPacman 這類高維度 Atari 環境中，agent 的表現仍容易受到探索動作、幽靈位置、路徑選擇與 Q-value 更新震盪影響。
- 本實驗中，agent 的最佳單局分數達到 5,500 分。此結果顯示 DQN-based agent 已經不只是隨機行動，而是能夠學到一定程度的得分與生存策略。從 training reward 與 evaluation average reward 的綜合圖可以看到，訓練期間的原始 episode reward 變異非常大。部分 episode reward 可達 2,000 至 4,000 分左右，但也有許多 episode 分數偏低。這代表 agent 偶爾能成功執行較佳策略，例如吃到較多豆子或存活較久，但尚無法穩定地在每一局中重現高分表現。

● 學習曲線：



從 Evaluation Avg Reward 圖中可觀察到，平均 reward 在約 1.5M steps 後開始提升，並在約 3.4M steps 附近達到最高點。然而，後續 reward 仍有明顯下降與回升，表示 agent 雖然學到部分有效策略，但整體 policy 尚未穩定收斂。



從紫色 training reward 可以看到，訓練過程中的 episode reward 變異非常大。部分 episode 的 reward 可以達到 2,000 到 4,000 分左右，但也有許多 episode 的 reward 接近低分區域。這代表 agent 在訓練過程中偶爾能找到高分路徑或成功存活較久，但並不是每一局都能穩定重現這樣的策略。

五、結論：

本實驗中，DQN agent 在 MsPacman 上最高取得 5,500 分，evaluation average reward 也在訓練中期明顯提升，顯示 agent 已學到部分有效策略；然而 reward curve 仍高度波動，代表 learned policy 尚未完全穩定，MsPacman 對 DQN 而言仍是一個需要更長訓練與更穩定演算法的高挑戰 Atari 任務。

此外實驗使用獎勵塑造(reward shaping)策略設計，來協助 agent 學習，包括對吃普通豆子、吃能量豆、吃幽靈給予額外 reward，並對靠近不可食幽靈、停止不動與生命值損失給予懲罰。這些設計可以提供更密集的學習訊號，使 agent 更容易分辨哪些行為有利於得分與生存。不過，reward shaping 也可能影響 agent 的行為偏好，例如過度追求短期吃豆 reward，而忽略更長期的安全路徑規劃。因此後續實驗可以進一步比較有無 reward shaping 的結果，以確認其實際貢獻。

整體而言，本實驗證明 DQN 可以在 MsPacman 中學到基本遊戲策略，但在 5M steps 的訓練限制下尚未完全收斂。若要進一步提升表現，可以增加訓練步數，或使用 Double DQN、Dueling DQN、Prioritized Experience Replay 等方法降低 Q-value 估計誤差並提升樣本效率。


Atari Enduro (PPO)

遊戲位置：<https://ale.farama.org/environments/enduro/>

一、遊戲摘要與目標：

- 遊戲目標：
扮演一名參加「National Enduro」耐力賽的賽車手。每天的目標是超越一定數量的車輛 才能繼續比賽：
 - 第一天：需超越 200 輛車。
 - 之後每天：需超越 300 輛車。
 - 若未達成每日超車目標，遊戲即結束。
- 觀測 (Observation space)：
Enduro-v5 支援三種觀察模式：
 - RGB 模式：Box(0, 255, (210, 160, 3), np.uint8)
 - RAM 模式：Box(0, 255, (128,), np.uint8)
 - 灰階模式：Box(0, 255, (210, 160), np.uint8)
- 動作空間 (Action Space)：
Enduro-v5 的動作空間是 Discrete(9)，代表有 9 種可能的操作：

Value	Meaning
0	NOOP
1	FIRE
2	RIGHT
3	LEFT
4	DOWN
5	DOWNRIGHT
6	DOWNLEFT
7	RIGHTFIRE
8	LEFTFIRE



若啟用 full_action_space=True，則可使用 Atari 2600 的全部 18 種動作。

- 遊戲特性：
 - 得分方式 (Reward)：每超越一輛車可獲得 1 分。
 - 應用場景：
Enduro-v5 常被用於訓練強化學習代理人 (如 PPO、DQN 等)，因為它具有：
 - ◆ 明確的目標 (超車)
 - ◆ 時間限制 (每日挑戰)
 - ◆ 動態環境 (白天與夜晚切換)

二、環境與工具：

- 訓練參數調整：

參數名稱	參數值	說明
gpu	True	是否使用 GPU
training_steps	1e8	總訓練步數 $1 * 10^8$ 的簡寫，即是一億步
update_sample_count	10000	每次更新所收集的樣本數
discount_factor_gamma	0.99	折扣因子 γ
discount_factor_lambda	0.95	GAE 的 λ 參數
clip_epsilon	0.2	PPO 剪輯參數 ϵ
max_gradient_norm	0.5	梯度裁剪的最大範圍
batch_size	128	每次更新的批次大小
logdir	log/...	日誌存放路徑
update_ppo_epoch	3	每次更新時的迭代次數
learning_rate	$2.5e-4$	學習率

value_coefficient	0.5	狀態值損失的權重
entropy_coefficient	0.01	熵獎勵的權重
horizon	128	GAE 回放緩衝區的時間範圍
env_id	ALE/Enduro-v5	Atari 環境 ID
eval_interval	100	評估間隔（單位：訓練迴圈數）
eval_episode	3	每次評估的遊戲回合數

Enduro-v5 的動作空間為 Discrete(9)，代表 agent 可選擇 9 種操作；若啟用 full_action_space=True，則可使用 Atari 2600 的完整 18 種動作。

- PPO 方法說明：

本任務使用 Proximal Policy Optimization, PPO 訓練 Enduro agent。PPO 是一種 policy gradient 方法，直接學習策略函數 $\pi_\theta(a|s)$ ，也就是在狀態 s 下選擇動作 a 的機率分布。相較於 DQN 以 Q-value 選擇動作，PPO 直接最佳化 policy，因此適合用於具有大量連續決策與高維度影像輸入的 Atari 任務。

PPO 的核心概念是限制每次策略更新的幅度，避免 policy 在一次更新中變化過大而導致訓練不穩定。本實驗使用 PPO clipped objective，其主要形式如下：

$$L^{CLIP}(\theta) = \mathbb{E}_t [\min(r_t(\theta)A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)A_t)]$$

其中 $r_t(\theta)$ 是新舊 policy 的機率比值， A_t 是 advantage estimate， ϵ 是 PPO 的 clipping threshold。本實驗設定 clip_epsilon=0.2，表示每次 policy update 的變動幅度會被限制在一定範圍內，以提升訓練穩定性。

- GAE 與 Advantage Estimation：

本實驗使用 Generalized Advantage Estimation, GAE 估計 advantage。GAE 能在 bias 與 variance 之間取得平衡，使 policy gradient 更新更穩定。

Parameter	Value	說明
discount factor gamma	0.99	控制長期 reward 的折扣
discount factor lambda	0.95	GAE 的 λ 參數，用於平衡 bias 與 variance

三、方法與實作：

- Atari 賽車遊戲，回報稀疏，挑戰較高，Enduro 的 reward 設計相對明確：每超越一輛車獲得 1 分。因此，agent 的學習目標可以理解為：在避免碰撞與維持高速行駛的前提下，盡可能穩定地超越更多車輛。
- 本任務的挑戰主要來自以下幾點：
 - 高速動態環境：車輛與道路會快速變化，agent 必須即時做出方向與速度控制。
 - 長期策略需求：短期超車不一定代表長期高分，過度冒險可能導致碰撞並降低後續表現。
 - 視覺輸入複雜：agent 需從 Atari 畫面中判斷道路、敵車與自身位置。
 - 環境變化：Enduro 包含白天、夜晚等視覺條件變化，使策略需要具備一定泛化能力。
- 訓練結果：

```
=====
Evaluating...(Recording videos...)
Max Level (Day) in this episode: 27
episode 1 reward: 2641.0
Max Level (Day) in this episode: 27
episode 2 reward: 2701.0
Max Level (Day) in this episode: 27
episode 3 reward: 2368.0
Max Level (Day) in this episode: 27
episode 4 reward: 2709.0
Max Level (Day) in this episode: 27
episode 5 reward: 2380.0
Warning: Failed to save evaluation image: 'AtariPPOAgent' object has no attribute 'episode_idx'
average score: 2559.8
=====
```

- 程式碼分析摘要：

- 使用 GAE (Generalized Advantage Estimation)：有助於穩定策略梯度估計。
- FrameStack + AtariPreprocessing：正確處理 Atari 圖像輸入，符合論文標準。
- PPO 演算法核心完整：包括 surrogate loss、value loss、entropy bonus。
- TensorBoard 支援：可視化訓練過程，利於 debug 與調參。


四、實驗結果：

- 目標：Enduro-v5 第 9 關以上：




本實驗原先設定目標為達到 Enduro-v5 第 9 關以上。實驗結果顯示，訓練後的 PPO agent 在 evaluation 中最高可達 Day 27 分數高達 14,637，已明顯超過原先目標，代表 agent 已學到穩定的超車與避車策略。

- 學習曲線：



隨著訓練步數增加，episode reward 整體呈現上升趨勢。前期 reward 快速提升，表示 agent 學會基本駕駛與超車；中後期雖仍有波動，但最高 reward 可達約 2.3k~2.4k，顯示 PPO agent 已能形成較穩定的長期超車策略。



Raw reward 顯示訓練過程中 episode 表現具有明顯變異，但 reward 分布隨訓練步數逐漸上移。後期多數 episode reward 可達 1500 以上，部分 episode 接近 2300，表示 agent 已學到有效的超車與避車策略，但仍會受到環境變化與碰撞事件影響。

五、結論：

Enduro 是一個需要即時反應與長期穩定控制的 Atari 賽車環境。由於 reward 來自超越車輛，agent 必須在高速行駛下避免碰撞，同時盡可能維持有效超車路線。這使得 Enduro 不只測試 agent 的短期反應能力，也測試其是否能在長時間 episode 中維持穩定策略。本實驗結果顯示，PPO agent 的 episode reward 隨訓練步數增加而明顯提升，且 evaluation 結果最高達到 Day 27，平均 reward 約 2559.8。這代表 PPO 能有效學習 Enduro 的駕駛策略。PPO 的 clipped objective 限制每次 policy update 的幅度，降低策略震盪；GAE 則提升 advantage estimation 的穩定性；entropy bonus 保留探索能力，避免過早收斂；FrameStack 與 AtariPreprocessing 則讓 agent 能從連續影像中判斷速度與車輛相對位置。

在 raw episode reward 仍有明顯波動，表示策略雖然已大幅改善，但仍非完全穩定。造成波動的原因可能包括車輛排列變化、碰撞造成速度損失、日夜場景轉換，以及長時間控制過程中的錯誤累積。未來可以進一步增加 evaluation episode 數量、調整 entropy coefficient、使用更長訓練步數，或比較不同 PPO 超參數設定，以更完整分析 agent 的穩定性。

整體來說，本任務證明 PPO 在 Enduro-v5 上能學到明確且有效的駕駛策略。相較於只觀察最高分，更重要的是 reward curve 顯示出長期上升趨勢，代表 policy 的平均品質隨訓練步數持續改善。